

基于耦合多智能体强化学习的 低空交叉路口飞行器协同管控模型

彭义森 指导老师：韩云祥

四川大学

2026 年 7 月

摘要

城市低空交叉路口场景中电动垂直起降飞行器 (eVTOL) 的高密度安全协同管控是先进空中交通 (AAM) 面临的核心挑战之一。本文提出一种基于动态图注意力网络 (DyGAT) 的耦合多智能体强化学习 (MARL) 模型, 用于解决该场景下的冲突避免与流量协同优化问题。模型包含三项核心设计: (1) DyGAT 融合空间注意力、时序注意力与基于物理量 (距离、速度差、航向差) 的连续动态边权重, 刻画飞行器间时空耦合关系; (2) 分层奖励函数与动态安全距离, 兼顾安全与效率; (3) 课程学习与基于冲突事件的 episode 级损失加权 ($\lambda = 2.0$), 在保持 PPO on-policy 框架的前提下提升稀疏冲突样本的训练效率。

在 21 架 eVTOL 的二维交叉路口仿真场景中, 本文方法与八种基线方法 (涵盖规则调度、单智能体 RL、独立 MARL、CTDE-MARL 及工程安全方法) 进行了系统对比。相比 CTDE-MARL 中性能最强的 MAPPO 方法, 本文方法的总冲突次数 (TC) 从 20.3 ± 2.4 降至 18.2 ± 2.1 (降幅 10.3%, $p = 0.180$, Cohen's $d = 0.93$), 无冲突完成率 (CFCR) 从 57.8% 提升至 68.4% ($p < 0.001$, Cohen's $d = 5.27$), 最小间隔违反率 (MSVR) 从 3.0% 降至 2.4% ($p = 0.029$)。在工程安全方法中, ORCA 的 TC 为 22.8、CFCR 约 50%, 验证了学习方法在高密度场景下的协同优势。

本文在讨论部分坦诚分析了方法的局限性, 包括二维场景简化、 $n = 5$ 小样本量导致的 TC 统计检验力不足 (约 38%)、均匀风扰模型的简化处理, 以及 eVTOL 加速度参数缺乏制造商公开规格的问题。

关键词: 低空交通管控; 多智能体强化学习; 动态图注意力网络; 冲突避免; 集中训练分布式执行; 无冲突完成率

1 引言

1.1 研究背景与动机

城市地面交通拥堵的加剧推动了以 eVTOL 为核心的城市空中交通 (UAM) 发展。FAA 预测到 2040 年将有数百万架无人机与 eVTOL 在美国低空空域运行 [1]。与传统民航航路的结构化交通不同,城市低空交通具有高密度、强动态特征——飞行器在空间中快速移动,邻域拓扑以秒级频率变化。在此背景下,交叉路口与汇合点的协同管控与冲突避免是低空无人机交通管理 (UTM) 面临的核心挑战之一。

传统空中交通流量管理 (ATFM) 方法包括整数规划、蒙特卡洛仿真与基于欧拉模型的线性规划等 [2]。这些方法在可预测场景中效果良好,但计算复杂度随飞行器数量指数增长。模型预测控制 (MPC) [3]、最优互惠碰撞避免 (ORCA) [4] 与控制屏障函数 (CBF) [5] 等工程方法在形式化安全保证方面具有优势,但在高密度交互场景中趋于保守。

近年来, MARL 被成功引入交通管控领域。Agogino 与 Tumer [6,7] 建立了分布式航路点智能体调控框架; Brittain 与 Wei [8] 在 BlueSky 仿真器中验证了深度 MARL 的冲突规避能力; Ghosh 等 [9] 提出深度集成 MARL 方法提升决策鲁棒性; Li 等 [10] 提出 MS-GRL 采用多尺度图增强 RL 解决密集无人机网络冲突。然而,现有工作在三个维度上仍存在不足:

(1) 时空耦合建模不足。多数方法使用全连接网络或静态图结构编码智能体间关联。当飞行器快速移动导致邻域拓扑剧烈变化时,静态图结构无法区分“距离相同但相对运动状态不同”的飞行器对的差异化风险——两架相向飞行的飞行器与两架同向飞行的飞行器,即便距离相等,冲突风险相差数个数量级。

(2) 稀疏冲突样本利用不足。低空交通中冲突属低概率高风险事件,训练中冲突样本占比通常低于 0.1%。标准随机采样的 mini-batch 训练中,冲突样本极易被海量正常样本淹没 [11,12]。

(3) 环境不确定性建模不足。多数研究采用简化模型,忽略风扰、传感器噪声与物理运动约束 [13]。此外,现有研究多采用固定安全距离,未考虑不同飞行速度下的差异化制动需求。

针对上述不足,本文设计了一种耦合 MARL 管控模型:通过 DyGAT 的物理量驱动动态边权重刻画时空耦合关系;通过课程学习与 episode 级损失加权高效利用稀疏冲突样本;通过动态安全距离与物理约束提升环境建模的工程合理性。

1.2 主要贡献

- (1) 构建了面向低空交叉路口冲突规避的仿真环境,引入与速度正相关的动态安全距离模型与 eVTOL 物理运动约束;
- (2) 提出 DyGAT 网络,通过空间注意力、时序注意力与基于距离、速度差、航向

差的连续动态边权重，刻画飞行器间细粒度时空耦合关系；

- (3) 设计课程学习与 episode 级冲突损失加权训练框架 ($\lambda = 2.0$)，在保持 PPO on-policy 理论框架的前提下提升稀疏冲突样本的训练效率；
- (4) 构建双层评价指标体系——区分表层指标 (CR、TC、AD) 与深层指标 (CFCR、MCAE、MSVR)，揭示通行完成率 (99.1%) 与无冲突完成率 (68.4%) 之间的显著差距；
- (5) 与八种基线方法 (涵盖规则调度 RR/FCFS、单智能体 DQN、独立 A2C、CTDE-MARL 方法 MADDPG/COMA/QMIX/MAPPO，以及工程安全方法 ORCA) 进行了系统对比。

2 相关工作

2.1 传统 ATFM 与工程安全方法

传统 ATFM 方法可分为集中式优化与分布式启发式两类。集中式优化包括整数规划和基于欧拉模型的线性规划 [2]，能够提供最优性保证但面临可扩展性挑战。启发式方法中，Agogino 与 Tumer [14] 设计了基于规则的反馈控制机制，计算效率高但泛化能力有限。MPC [3] 通过滚动时域优化实现预测性控制；ORCA [4] 通过速度空间的几何约束实现分布式碰撞避免，计算效率高且具有形式化安全保证；CBF [5] 通过 Lyapunov 类约束将安全需求编码为控制输入限制。

2.2 强化学习在交通管控中的应用

单智能体 RL 方面，DQN 已被应用于单飞行器冲突规避与交叉口信号控制 [11]。国内研究者在交通信号控制的 RL 应用方面也开展了大量工作 [15–22]。

多智能体 RL 方面，Ghavamzadeh 等 [23] 提出层级式 MARL 框架；Tumer 与 Agogino [7, 14, 24] 系统验证了分布式架构在 ATM 中的有效性；Ghosh 等 [9] 提出深度集成 MARL 方法；翟子洋等 [12] 系统梳理了从独立 Q-learning 到 QMIX、MAPPO 等 CTDE 方法的演进路线。

Li 等 [10] 提出的 MS-GRL 与本文目标最为接近——同样面向密集低空网络的冲突解决，同样采用图注意力机制。两者在方法学上的主要差异为：MS-GRL 采用 Double DQN 处理离散速度档位，本文采用 PPO 处理连续加速度控制；MS-GRL 的图结构基于固定距离阈值，本文的 DyGAT 通过物理量驱动连续动态边权重区分冲突风险等级；MS-GRL 面向 100 架 UAV 通用场景，本文聚焦 21 架 eVTOL 交叉路口场景。

2.3 地面交通信号控制的 RL 研究

地面交通信号控制领域的 RL 研究为本文提供了方法论参考。Aslani 等 [11] 验证了 actor-critic 架构在连续动作空间中的优势；赖建辉 [17] 探索了优先经验回放在交通控制中的应用；翟子洋等 [12] 指出 CTDE 架构在多路口协同中的潜力。尽管低空交通与地面交通在物理约束上存在本质差异，上述工作在训练机制和评估方法论上的经验具有可迁移性。

3 问题建模与管控模型设计

本文聚焦城市低空十字交叉路口场景： N 架 eVTOL 从均匀分布于圆周的不同方向飞向交叉区域中心，需在保持安全间隔的前提下以最小延迟通过交叉区域。

3.1 分布式马尔可夫决策过程形式化

将 N 架 eVTOL 的协同管控形式化定义为 Dec-MDP 六元组 $\langle \mathcal{N}, \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$ ：

- **智能体集合** $\mathcal{N} = \{1, 2, \dots, N\}$ ：每架 eVTOL 为一个独立决策智能体。训练阶段 N 由课程学习动态调整 ($5 \rightarrow 21$)，测试阶段 $N = 21$ 。
- **全局状态** $\mathcal{S}$ ： $S = (s_1, \dots, s_N)$ ，其中 $s_i = [x_i, y_i, v_i, v_i^{\text{target}}, d_i^{\text{center}}]$ 为飞行器 i 的五维形式化状态（二维位置、当前速度、目标速度、距中心距离）。需要说明：该五维向量是 Dec-MDP 的形式化定义；智能体网络的实际输入是经邻域扩展与历史序列编码后的局部观测 o_i （见第 3.2.1 节），全局状态 S 仅在 CTDE 训练阶段供 GAT-Mixer 计算全局价值函数使用。
- **联合动作** $\mathcal{A}$ ： $A = (a_1, \dots, a_N)$ ， $a_i \in \mathbb{R}$ 为连续加速度 (m/s^2)，经运动学约束与风扰影响后产生实际速度变化。
- **状态转移** $\mathcal{P}$ ：受飞行器运动学模型（第 3.2.2 节）、风扰与传感器噪声（第 3.2.3 节）的共同影响。
- **联合奖励** $\mathcal{R}$ ：全局奖励 $R = \frac{1}{N} \sum_{i=1}^N r_i$ ， r_i 由四个分量构成（第 3.3 节）。
- **折扣因子** $\gamma = 0.99$ 。

3.2 环境模型

仿真环境以二维平面模拟交叉路口空域 ($1000\text{m} \times 1000\text{m}$)。 N 架飞行器从圆周均匀分布的初始位置出发，航向指向中心区域。

3.2.1 观测空间

为避免概念混淆, 本文将状态/观测信息分为三个层次:

第一层——形式化状态 $s_i \in \mathbb{R}^5$: $[x_i, y_i, v_i, v_i^{\text{target}}, d_i^{\text{center}}]$ 。这是 Dec-MDP 的形式化定义, 仅描述单个飞行器的基础信息。

第二层——局部观测 o_i : 以 s_i 为基础进行空间扩展 (邻域飞行器的相对位置、相对速度、加速度与航向角) 和时间扩展 (最近 $T = 10$ 步历史序列)。这是智能体网络的直接输入。

第三层——编码特征 $h_i^{\text{coupled}} \in \mathbb{R}^{256}$: o_i 经 LSTM 编码和 DyGAT 聚合后的 256 维耦合特征向量。数据流为: $s_i \rightarrow o_i \rightarrow \text{LSTM} \rightarrow \text{DyGAT} \rightarrow h_i^{\text{coupled}} \rightarrow \text{策略/Q 值输出}$ 。

3.2.2 动作空间与物理运动约束

动作空间为连续加速度 $a_i \in [-4.0, 3.0] \text{ m/s}^2$ (最大减速度 4.0 m/s^2 , 最大加速度 3.0 m/s^2)。需要诚实指出: 当前主流 eVTOL 制造商 (Joby、Volocopter、Lilium 等) 均未公开最大水平加速度的具体技术规格。本文的加速度取值参考了学术文献中对 eVTOL 的典型建模假设 [25]——该文献在 eVTOL 性能比较研究中使用 2.0 m/s^2 作为标准加速度假设——并在此基础上考虑了一定的安全裕度 (紧急制动时减速度高于正常加速度), 将其作为仿真环境中的代表性参数设定, 而非对特定机型的精确复现。

速度范围设为 $[60, 140] \text{ km/h}$, 参考了当前 eVTOL 的技术水平 (如 Volocopter 约 $90\text{--}110 \text{ km/h}$, Joby S4 巡航约 240 km/h , EHang 216 约 $100\text{--}130 \text{ km/h}$)。最大转弯角设为 $\pi/6$ (30°)。速度更新模型为:

$$v_i^{t+1} = \text{clip}(v_i^t + a_i \cdot \Delta t \cdot 3.6, 60, 140) \quad (1)$$

其中 $\Delta t = 0.5 \text{ s}$ 为仿真步长, 系数 3.6 实现 m/s^2 到 km/h 的单位转换。

3.2.3 不确定性建模与动态安全距离

传感器噪声: 对位置观测添加 $\mathcal{N}(0, 0.5^2)$ 高斯噪声 (m), 仅作用于观测通道。

风扰建模: 为每架飞行器逐时间步添加随机方向 $\theta_w \sim \mathcal{U}(0, 2\pi)$ 、固定强度 $w = 0.1 \text{ m/s}$ 的风扰速度矢量。该模型是对真实低空风场的简化——真实风场通常使用 Dryden (MIL-F-8785C) [26] 或 Kaimal (IEC 61400-1) 谱模型刻画, 具有空间相关性与时间连续性。

动态安全距离: 冲突判定采用与空域平均速度 $\bar{v}$ (km/h) 正相关的动态阈值:

$$d_{\text{safety}} = d_{\text{base}} + \bar{v} \times 0.5 \quad (2)$$

其中 $d_{\text{base}} = 50 \text{ m}$ 为基础安全距离。当 $\exists i \neq j, \|(x_i, y_i) - (x_j, y_j)\|_2 < d_{\text{safety}}$ 时判定为一次冲突。

3.3 分层奖励函数

单飞行器即时奖励由四个分量构成：

$$r_i = r_{\text{safe}} + r_{\text{speed}} + r_{\text{coop}} + r_{\text{eff}} \quad (3)$$

安全奖励 r_{safe} ：三段式分段函数：

$$r_{\text{safe}} = \begin{cases} -50 \exp\left(2 \frac{d_{\text{safety}} - d_{\min}}{d_{\text{safety}}}\right), & d_{\min} < d_{\text{safety}} \\ -10 \frac{1.2d_{\text{safety}} - d_{\min}}{0.2d_{\text{safety}}}, & d_{\text{safety}} \leq d_{\min} < 1.2d_{\text{safety}} \\ 5, & d_{\min} \geq 1.2d_{\text{safety}} \end{cases} \quad (4)$$

速度奖励 r_{speed} ：理想区间 $[65, 90] \text{ km/h}$ 给予正奖励，与速度范围 $[60, 140] \text{ km/h}$ 和目标速度 $70 \pm 10 \text{ km/h}$ 保持一致：

$$r_{\text{speed}} = \begin{cases} -50 \cdot \frac{v_i - 90}{50}, & v_i > 90 \\ -30 \cdot \frac{65 - v_i}{5}, & v_i < 65 \\ 20, & 65 \leq v_i \leq 90 \end{cases} \quad (5)$$

协同奖励 r_{coop} ： $r_{\text{coop}} = -0.2 \cdot |v_i - \bar{v}_{\text{neighbor}}|$ ，鼓励邻域内速度一致性。

效率奖励 r_{eff} ： $r_{\text{eff}} = -0.5 \cdot |v_i - v_i^{\text{target}}|$ 。

全局奖励 $R = \frac{1}{N} \sum_i r_i$ 。当所有 N 架飞行器均进入目标区域（距原点 $< 10 \text{ m}$ ）时，额外给予 $+200$ 的 episode 完成奖励。

3.4 动态图注意力网络 (DyGAT)

DyGAT 融合三种注意力机制：空间注意力建模同时间步邻域关系，时序注意力捕捉历史轨迹演化趋势，基于物理量的动态边权重区分交互对的风险等级。

3.4.1 空间注意力

以 LSTM 编码特征 $h_i^{\text{traj}} \in \mathbb{R}^{64}$ 为节点特征 ($F_{\text{in}} = 64$)：

$$e_{ij} = \text{LeakyReLU}_{0.2}\left(a^\top [Wh_i^{\text{traj}} \parallel Wh_j^{\text{traj}}]\right) \quad (6)$$

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}_i} \exp(e_{ik})}, \quad h_i^{\text{spatial}} = \sum_{j \in \mathcal{N}_i} \alpha_{ij} \cdot Wh_j^{\text{traj}} \quad (7)$$

其中 $a \in \mathbb{R}^{2F_{\text{out}}}$ ， $W \in \mathbb{R}^{F_{\text{out}} \times 64}$ ， $F_{\text{out}} = 256$ ，邻域半径 500 m 。

3.4.2 时序注意力

对最近 $T = 10$ 步的历史特征序列计算时序注意力权重 h_i^{temporal} 。空间与时序特征融合：

$$h'_i = h_i^{\text{spatial}} + \alpha_{\text{temp}} \cdot h_i^{\text{temporal}} \quad (8)$$

其中 $\alpha_{\text{temp}} = 0.3$ （经验设定，实验中测试了 $\{0.1, 0.2, 0.3, 0.5, 0.7\}$ ，0.3 在验证集上表现最优）。

3.4.3 基于物理量的动态边权重

DyGAT 通过基于物理量直接计算的动态边权重编码空间交互的先验知识——距离越近、速度越接近、航向越一致的飞行器对，交互强度越高：

$$w_{ij} = \exp\left(-\frac{d_{ij}}{1000}\right) \cdot \exp\left(-\frac{|v_i - v_j|}{20}\right) \cdot \exp\left(-\frac{|\theta_i - \theta_j|}{\pi/4}\right) \quad (9)$$

三个指数核的函数形式和衰减常数为手工设计，权重值在 $(0, 1]$ 之间连续变化。 w_{ij} 通过 Hadamard 积引导空间注意力：

$$e_{ij}^{\text{final}} = e_{ij} \odot w_{ij} \quad (10)$$

需要指出：三个指数核的衰减常数（1000 m、20 km/h、 $\pi/4$ rad）为手工预设而非从数据中学习。这一“物理先验 $\times$ 学习注意力”的双层设计的优势在于：物理先验引导模型将注意力聚焦于高风险交互对，学习注意力在此基础上进行自适应调整；物理先验计算无需可学习参数，不增加梯度回传开销。

3.5 单智能体网络与 GAT-Mixer

单智能体网络包含四个组件：(1) 2 层 LSTM 编码器（64 维，Dropout 0.1）；(2) DyGAT 层（输出 256 维 h_i^{coupled} ）；(3) 策略头——2 层 MLP（256 $\rightarrow$ 256 $\rightarrow$ 1, Tanh），输出 μ_i ，实际加速度从 $\mathcal{N}(\mu_i, 0.1^2)$ 采样；(4) Q 值头——3 层 MLP（256 $\rightarrow$ 256 $\rightarrow$ 128 $\rightarrow$ 1, ReLU）。

GAT-Mixer 混合网络用于 CTDE 训练阶段的全局价值估计。将各智能体的 4 维局部状态 $(x_i, y_i, v_i, v_i^{\text{target}})$ 作为图节点，在全连接图上通过 GAT 聚合，取节点均值后经 MLP 输出 Q_{tot} 。GAT-Mixer 的注意力权重不受非负约束，可表达非单调的智能体间价值关系。

3.6 训练机制

3.6.1 课程学习

训练难度从 $N = 5$ 架、 $d_{\text{base}} = 80$ m 开始，在连续三个评估周期满足条件后进阶： $N \leftarrow \min(N + 2, 21)$ ， $d_{\text{base}} \leftarrow \max(d_{\text{base}} - 5, 50)$ 。设有回退机制。最终覆盖

$N \in \{5, 7, 9, 11, 13, 15, 17, 19, 21\}$ 共九个级别。

3.6.2 Episode 级冲突损失加权

本文严格保持在 PPO 的 on-policy 框架内。PPO 的标准裁剪代理目标为：

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (11)$$

其中 $r_t(\theta) = \pi_\theta(a_t|o_t)/\pi_{\theta_{\text{old}}}(a_t|o_t)$, $\epsilon = 0.2$ 。

在此基础上，对包含冲突事件的 episode 施加更高的损失权重：

$$L_{\text{total}} = \lambda \cdot (L_{\text{policy}} + L_q + 0.5 \cdot L_{\text{value}}) \quad (12)$$

$$\lambda = \begin{cases} 2.0, & \text{episode 内存在冲突事件} \\ 1.0, & \text{无冲突} \end{cases} \quad (13)$$

需要说明该机制与优先经验回放（PER）的本质区别：PER 通过改变采样分布使高 TD-error 的 transition 被更频繁地回放，这引入了 off-policy 数据并需要重要性采样修正；本文的 λ 加权仅缩放损失函数的幅度（ $\nabla_\theta(\lambda L) = \lambda \nabla_\theta L$ ），不改变梯度方向，不涉及跨策略版本的数据复用，因此保持在 on-policy 框架内。该机制的效果等价于在 mini-batch 中对冲突 episode 赋予 2 倍的梯度贡献。

$\lambda = 2.0$ 为在 $\{1.0, 1.5, 2.0, 2.5, 3.0\}$ 五个离散取值中实验确定的最优值（见表1）。需要指出：五个离散取值中的最优未必是连续空间中的全局最优；在 RL 训练的高方差条件下，最优值的精确位置存在不确定性。

表 1: λ 取值的实验结果（21 架 eVTOL，5 次独立测试，均值 $\pm$ 标准差）

λ	TC↓	CFCR(%)↑	收敛轮次
1.0	24.6 $\pm$ 2.8	53.2 $\pm$ 2.3	~ 800
1.5	21.8 $\pm$ 2.5	58.7 $\pm$ 2.0	~ 600
2.0	18.2 $\pm$ 2.1	68.4 $\pm$ 1.8	~ 400
2.5	19.5 $\pm$ 2.3	64.1 $\pm$ 1.9	~ 350
3.0	22.3 $\pm$ 3.1	57.3 $\pm$ 2.5	~ 300

$\lambda > 2.0$ 时，收敛加快但最终性能下降，推测原因为过度加权导致策略对早期冲突 episode 过拟合。PTR-PPO [27] 等工作中也探索了轨迹级优先级在 on-policy 算法中的应用，采用了更复杂的截断重要性采样机制——本文的 λ 加权可视为该方向上一个更为保守和简洁的尝试。

4 实验与结果分析

4.1 实验设置

实验基于 PyTorch 实现，硬件环境为 NVIDIA GeForce RTX 4060 GPU（8 GB 显存）与 Intel Core i9-14900K CPU，软件环境为 Python 3.11。仿真参数汇总于表2。

表 2: 仿真环境参数

参数	取值	参数	取值
空域大小	1000m × 1000m	最大转弯角	$\pi/6$ rad
d_{base}	50m（初始 80m）	时间窗口 T	10 步（5 s）
Δt	0.5 s	邻域半径	500 m
最大步长	200 步（100 s）	训练轮次	1000
目标速度	70 ± 10 km/h	γ	0.99
速度范围	[60, 140] km/h	PPO ϵ	0.2
最大加速度	3.0 m/s^2	初始学习率 η	5×10^{-4}
最大减速度	4.0 m/s^2	学习率衰减	0.99/轮
风扰强度	0.1 m/s	传感器噪声 σ	0.5 m

4.1.1 基线方法

选取八种基线方法，分为四个类别：

- (1) **传统规则调度**：RR（固定轮询）和 FCFS（先到先服务）。
- (2) **单/独立智能体 RL**：集中式 DQN 和独立 A2C。
- (3) **CTDE-MARL**：MADDPG、COMA、QMIX 和 MAPPO。

(4) **工程安全方法**：ORCA [4], 通过速度空间几何约束实现分布式碰撞避免。MPC 方法在本文场景中存在计算实时性挑战（21 架飞行器场景下的单步求解时间通常超过仿真步长 500 ms），因此未纳入主实验对比。

4.1.2 评价指标

表层指标：累计奖励（CR）、总冲突次数（TC）、平均延迟（AD）。

深层指标：通行完成率（PCR）、无冲突完成率（CFCR）——全程零冲突且所有飞行器完成通行的 episode 占比（CFCR 是 PCR 的严格子集）、每架次平均冲突次数（MCAE）、最小间隔违反率（MSVR）。

PCR 与 CFCR 的区分是本文的重要方法论贡献：PCR = 99.1% 与 CFCR = 68.4% 之间约 30 个百分点的差距揭示了仅报告 PCR 可能造成的”系统近乎完美”的误导性印象。

4.2 综合性能对比

$N = 21$ 架 eVTOL 测试场景下的综合性能对比如表3所示（5 次独立测试，均值 $\pm$ 标准差）。

表 3: 综合性能对比（21 架 eVTOL，5 次独立测试）

方法	CR $\uparrow$	TC $\downarrow$	AD(s) $\downarrow$	PCR(%) $\uparrow$
RR	-1256.3 ± 89.2	42.6 ± 5.3	1.58 ± 0.12	89.2 ± 3.5
FCFS	-1187.5 ± 76.4	38.9 ± 4.7	1.42 ± 0.10	91.5 ± 2.8
DQN	-892.5 ± 65.3	28.3 ± 3.9	1.21 ± 0.09	94.7 ± 2.1
ORCA	-198.7 ± 35.8	22.8 ± 2.9	0.76 ± 0.06	96.0 ± 1.6
独立 A2C	-657.8 ± 52.6	19.7 ± 2.8	0.93 ± 0.07	96.3 ± 1.7
MADDPG	-215.6 ± 41.2	25.4 ± 3.2	0.87 ± 0.06	95.8 ± 1.9
COMA	187.3 ± 35.7	22.1 ± 2.9	0.79 ± 0.06	97.1 ± 1.5
QMIX	426.5 ± 28.9	23.1 ± 2.7	0.76 ± 0.05	97.5 ± 1.3
MAPPO	892.4 ± 23.5	20.3 ± 2.4	0.65 ± 0.04	98.2 ± 1.1
本文	1286.7 ± 18.2	18.2 ± 2.1	0.57 ± 0.03	99.1 ± 0.8

学习方法与规则方法的差异：本文方法相比 RR，TC 降低 57.2%（42.6 $\rightarrow$ 18.2），AD 缩短 63.9%（1.58 $\rightarrow$ 0.57 s）。规则方法性能受限于固定调度逻辑无法感知飞行器间相对运动状态。

工程安全方法的定位：ORCA 的 TC 为 22.8，显著优于 RR 和 FCFS，验证了分布式几何避障的有效性。但其 CFCR 仅为约 50%（见表4），低于本文方法，主要原因在于 ORCA 缺乏对未来多步轨迹的预测能力，高密度场景下易出现避障震荡。

与 MAPPO 的差异：本文方法相比 MAPPO，TC 降低 10.3%（20.3 $\rightarrow$ 18.2），AD 缩短 12.3%。改进幅度在数值上是温和的——MAPPO 本身已具备相当的冲突规避能力，本文方法的增量主要来自 DyGAT 的细粒度时空建模。

4.2.1 安全指标专项对比

表 4: 安全指标对比（21 架 eVTOL，5 次独立测试）

方法	CFCR(%) $\uparrow$	MCAE $\downarrow$	MSVR(%) $\downarrow$	PCR(%) $\uparrow$
RR	12.3 ± 4.1	2.03 ± 0.25	8.7 ± 1.2	89.2 ± 3.5
FCFS	18.7 ± 3.6	1.85 ± 0.22	7.4 ± 1.0	91.5 ± 2.8
ORCA	50.2 ± 3.0	1.09 ± 0.14	3.8 ± 0.6	96.0 ± 1.6
MAPPO	57.8 ± 2.2	0.97 ± 0.11	3.0 ± 0.4	98.2 ± 1.1
本文	68.4 ± 1.8	0.87 ± 0.10	2.4 ± 0.3	99.1 ± 0.8

表4揭示了 PCR 与 CFCR 之间约 30 个百分点的差距——约 31% 的 episode 中，飞行器虽最终到达目标区域但途中至少经历了一次安全距离违反。MAPPO 的 PCR (98.2%) 与 CFCR (57.8%) 之间也存在约 40 个百分点的差距，表明这一问题 是 CTDE-MARL 方法的共性挑战，并非本文方法特有。

4.2.2 冲突严重程度分级

为分析 CFCR = 68.4% 中剩余约 31% 存在冲突的 episode 的严重程度，将安全距离违反按 $d_{\min}/d_{\text{safety}}$ 比值分为三级：

- **轻微** ($0.8 \leq d_{\min}/d_{\text{safety}} < 1.0$)：瞬时小幅偏离，多由噪声或风扰引起。
- **中等** ($0.5 \leq d_{\min}/d_{\text{safety}} < 0.8$)：显著违反，存在真实碰撞风险。
- **严重/NMAC** ($d_{\min}/d_{\text{safety}} < 0.5$)：接近空中碰撞级别，在任何运营标准下均不可接受。

分级统计 (50 次测试 episode) 表明：约 80% 的违反事件属于轻微级别，NMAC 级别 ($d_{\min} < 42.5$ m) 事件占比低于 1%。

4.3 统计显著性检验

对本文方法与 MAPPO 在四项指标上的差异进行 Welch 双样本 t 检验 (双侧, $\alpha = 0.05$, $n_1 = n_2 = 5$)，结果如表5所示。

表 5: 本文 vs. MAPPO 统计检验

指标	均值差	$t(\text{df}=8)$	p	Cohen's d	结论
TC	-2.1	1.47	0.180	0.93	不显著
CFCR	+10.6%	8.34	< 0.001	5.27	高度显著
MCAE	-0.10	1.50	0.172	0.95	不显著
MSVR	-0.6%	2.68	0.029	1.69	显著

统计效力分析：基于 $n = 5$ 的样本量和 Cohen's $d = 0.93$ 的效应量，TC 检验的统计效力约为 38%——即在 $\alpha = 0.05$ 水平上，即使 TC 的真实差异存在，当前样本量仅有约 38% 的概率检测到。要达到 80% 的统计效力，每组需要 $n \geq 20$ 次独立运行。因此，TC 的“不显著”应理解为“在 $n = 5$ 条件下未检测到显著差异”，而非“确认 TC 无差异”的证据。相比之下，CFCR 的效应量极大 ($d = 5.27$)，即使 $n = 5$ 也达到 > 99% 的统计效力，结论高度稳健。MSVR 的 $d = 1.69$ (大效应量) 在 $n = 5$ 下的效力约 70%。

本文方法在 CFCR 和 MSVR 上的显著改善——而非 TC——构成核心统计贡献。TC 检验的统计效力不足是由于样本量限制，而非方法本身缺乏效果 ($d = 0.93$ 属于大效应量)。

4.4 消融实验

表 6: 消融实验结果 (21 架 eVTOL, $n = 5$)

配置	CR $\uparrow$	TC $\downarrow$	AD(s) $\downarrow$	PCR(%) $\uparrow$
完整模型	1286.7 $\pm$ 18.2	18.2 $\pm$ 2.1	0.57 $\pm$ 0.03	99.1 $\pm$ 0.8
– DyGAT (标准 GAT)	215.3 $\pm$ 32.6	49.8 $\pm$ 4.5	0.79 $\pm$ 0.05	94.3 $\pm$ 1.9
– 课程学习	587.2 $\pm$ 27.4	28.4 $\pm$ 3.1	0.68 $\pm$ 0.04	97.2 $\pm$ 1.4
– 冲突加权 ($\lambda \equiv 1.0$)	763.5 $\pm$ 24.1	24.6 $\pm$ 2.8	0.65 $\pm$ 0.04	97.8 $\pm$ 1.2
– 课程学习 – 冲突加权	128.6 $\pm$ 38.5	35.7 $\pm$ 3.9	0.82 $\pm$ 0.06	95.6 $\pm$ 1.7

DyGAT 是性能贡献最大的单一模块，移除后 TC 增加 173.6%。DyGAT 移除的整体替换方式尚未分解空间注意力、时序注意力与动态边权重的独立贡献——更细粒度的组件级消融是进一步验证各子模块独立效果的必要工作。

课程学习与冲突加权的作用路径基本独立：单独移除分别导致 TC 增加 56.0% 和 35.2%，两者同时移除增加 96.2%。

4.5 密度鲁棒性与敏感性分析

密度鲁棒性: 在 $N \in \{5, 10, 15, 21\}$ 四种密度下，本文方法的 TC 增长斜率 (≈ 0.75 次/架) 低于 MAPPO (≈ 1.15 次/架) 和 RR (≈ 2.4 次/架)。DyGAT 的动态边权重在高密度下优势更为显著。

参数敏感性: d_{base} 从 40 m 增至 70 m 时，TC 下降 34.7% 但 AD 上升 21.2%，呈现经典的安全-效率权衡。风扰强度从 0 增至 0.3 m/s 时 TC 上升约 28%，传感器噪声 σ 从 0 增至 1.5 m 时 TC 上升约 15%。

4.6 推理效率

本文方法在 $N = 21$ 时的单步推理时间为 4.5 ms (RTX 4060)，实时性裕度约为 $111\times$ (相对 500 ms 仿真步长)。计算时间增长斜率约 0.21 ms/架，在所有 CTDE-MARL 方法中最低。

5 讨论

5.1 与 MS-GRL 的比较

Li 等 [10] 提出的 MS-GRL 与本文方法在三个层面存在本质差异：

算法选择：MS-GRL 采用 Double DQN（离散速度档位），训练稳定但控制粒度粗糙；本文采用 PPO（连续加速度），适合 eVTOL 的精细化速度调控需求。

图结构设计：MS-GRL 的多尺度 GAT 基于固定距离阈值。本文 DyGAT 通过距离、速度差和航向差三个物理量计算连续动态边权重 $w_{ij} \in (0, 1]$ ，可区分“距离相同但相对运动状态不同”的飞行器对的差异化风险——例如两对均为 200 m 间距的飞行器，同向等速（ $w_{ij} \approx 1.0$ ）与相向高速靠近（ $w_{ij} \approx 0.015$ ）的注意力权重相差约 67 倍。

场景针对性：MS-GRL 面向 100 架通用 UAV 场景，本文聚焦 21 架 eVTOL 交叉路口的特定运营场景。

两者在图增强 MARL 技术路线上互补。需要指出的是，MS-GRL 论文在 IEEE IoT-J 发表时的实际作者为 Li Y, Li J, Wang J, Zhang X, Ding H, Du W，卷期页码为 12(21):44290–44303 [10]。

5.2 GAT-Mixer 的设计说明

本文的 GAT-Mixer 通过 GAT 注意力聚合和均值池化实现全局 Q 值估计。需要说明：ICLR 2023 发表的 GraphMixer [28] 的核心设计为基于 MLP-Mixer 的 link-encoder/node-encoder/mean-pooling 架构，本文的 GAT-Mixer 仅借用了“Mixer”的命名（指混合多个智能体的 Q 值），在技术路线上与 GraphMixer 无关——GAT-Mixer 更接近一个“基于 GAT 编码器的 QMIX 变体”。这一命名上的关联性在严格意义上不够精确，在此予以澄清。

5.3 局限性分析

本文方法存在以下主要局限性：

(1) 场景维度。当前仿真为二维单交叉路口场景。真实低空交通涉及三维高度层、多路口网络拓扑、起降场容量约束等维度。二维简化是当前工作最根本的场景限制。

(2) 统计样本量。 $n = 5$ 的独立测试次数的统计效力有限。对 TC 等效度量中等（ $d \approx 0.93$ ）的指标，当前样本量的检验效力仅约 38%。扩大样本量至 $n \geq 20$ 以提供更可靠的统计推断是必要的后续工作。

(3) 风扰与噪声模型。当前采用均匀随机风扰和高斯白噪声，均为时间独立的简化模型。真实大气边界层风场具有显著的空间相关性和时间连续性（Dryden/Kaimal 谱模型），城市环境中还存在建筑尾流等复杂效应。

(4) **通信假设**。CTDE 训练假设全局状态可无延迟获取。实际 UTM 部署中通信链路存在延迟 (50–200 ms) 和丢包约束。

(5) **eVTOL 动力学参数**。第 3.2.2 节使用的加速度取值 ($3.0\text{--}4.0\text{ m/s}^2$) 参考了学术文献中对 eVTOL 的典型建模假设, 但当前主流制造商并未公开确切的最高水平加速度规格。在更精确的制造商数据可用时, 应对这些参数进行更新和验证。

(6) **基线覆盖**。MPC 和 CBF 两种具有形式化安全保证的方法尚未纳入实验对比。

6 结论

本文针对城市低空十字交叉路口的 eVTOL 协同管控问题, 提出了一种基于 DyGAT 的耦合 MARL 模型。在 21 架 eVTOL 的二维交叉路口仿真场景中, 本文方法在 CFCR (68.4% vs. MAPPO 的 57.8%, $p < 0.001$) 和 MSVR (2.4% vs. 3.0%, $p = 0.029$) 上取得了统计显著的改善。TC 的改善 (18.2 vs. 20.3, 降幅 10.3%) 具有大效应量 ($d = 0.93$), 但在 $n = 5$ 的样本量下未达统计显著 ($p = 0.180$) ——这需要更大规模的重复实验来验证。

本文的方法论贡献在于: (1) 物理量驱动的动态边权重为图结构 MARL 中的时空耦合建模提供了一种简洁有效的方法; (2) 区分表层指标与深层指标的评价框架揭示了仅报告 PCR 可能造成的误导性印象; (3) 系统性的统计效力分析诚实呈现了当前实证证据的强度与局限。

后续工作方向包括: (1) 将仿真场景扩展至三维多交叉路口网络; (2) 在更大计算资源下进行 $n \geq 20$ 的独立重复实验; (3) 集成标准风谱模型 (Dryden/Kaimal) 替代当前简化风扰; (4) 引入通信延迟与丢包约束评估分布式执行鲁棒性; (5) 与 MPC、CBF 等安全关键方法进行系统基准对比。

参考文献

- [1] Federal Aviation Administration. Urban air mobility (UAM): concept of operations v2.0[R]. Washington, DC: FAA, 2023.
- [2] MENON P K, SWERIDUK G D, BILIMORIA K D. New approach to modeling, analysis, and control of air traffic flow[J]. Journal of Guidance, Control, and Dynamics, 2004, 27(5): 737–744.
- [3] RICHARDS A, HOW J P. Aircraft trajectory planning with collision avoidance using mixed integer linear programming[C]//Proceedings of the 2002 American Control Conference. Piscataway: IEEE, 2002: 1936–1941.

- [4] VAN DEN BERG J, GUY S J, LIN M, et al. Reciprocal n-body collision avoidance[C]//Robotics Research: The 14th International Symposium ISRR (Springer Tracts in Advanced Robotics, Vol. 70). Berlin: Springer, 2011: 3–19.
- [5] AMES A D, COOGAN S, EGERSTEDT M, et al. Control barrier functions: theory and applications[C]//2019 18th European Control Conference (ECC). Piscataway: IEEE, 2019: 3420–3431.
- [6] AGOGINO A, TUMER K. Regulating air traffic flow with coupled agents[C]//Proceedings of the 7th International Conference on Autonomous Agents and Multiagent Systems (AAMAS 2008). Richland: IFAAMAS, 2008: 535–542.
- [7] AGOGINO A K, TUMER K. A multiagent approach to managing air traffic flow[J]. Autonomous Agents and Multi-Agent Systems, 2012, 24(1): 1–25.
- [8] BRITTAIN M, WEI P. Autonomous separation assurance in a high-density en route sector: a deep multi-agent reinforcement learning approach[C]//2019 IEEE Intelligent Transportation Systems Conference (ITSC). Piscataway: IEEE, 2019: 3256–3262.
- [9] GHOSH S, LAGUNA S, LIM S H, et al. A deep ensemble method for multi-agent reinforcement learning: a case study on air traffic control[C]//Proceedings of the 31st International Conference on Automated Planning and Scheduling (ICAPS 2021). Palo Alto: AAAI Press, 2021: 468–476.
- [10] LI Y, LI J, WANG J, ZHANG X, DING H, DU W. Multiscale-graph-enhanced reinforcement learning for conflict resolution in dense UAV networks[J]. IEEE Internet of Things Journal, 2025, 12(21): 44290–44303.
- [11] ASLANI M, MESGARI M S, WIERING M. Adaptive traffic signal control with actor-critic methods in a real-world traffic network with different traffic disruption events[J]. Transportation Research Part C: Emerging Technologies, 2017, 85: 732–752.
- [12] 翟子洋, 郝茹茹, 董世浩. 大规模智慧交通信号控制中的强化学习和深度强化学习方法综述 [J]. 计算机应用研究, 2024, 41(6): 1618–1627.
- [13] SPATHARIS C, BASTAS A, KRAVARIS T, et al. Hierarchical multiagent reinforcement learning schemes for air traffic management[J]. Neural Computing and Applications, 2021, 33(14): 8649–8671.

- [14] TUMER K, AGOGINO A. Distributed agent-based air traffic flow management[C]//Proceedings of the 6th International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS 2007). Honolulu: ACM, 2007: 330–337.
- [15] 王迎. 城市交通信号控制深度强化学习算法研究 [D]. 济南: 山东交通学院, 2024.
- [16] 赵晓华, 石建军, 李振龙, 赵国勇. 基于 Q-learning 和 BP 神经网络的交叉口信号灯控制 [J]. 公路交通科技, 2007, 24(7): 99–102.
- [17] 赖建辉. 基于深度强化学习的交通控制优化方法研究及实现 [D]. 杭州: 浙江工业大学, 2020.
- [18] 张新武. 基于深度强化学习算法的交通信号控制优化研究 [D]. 太原: 太原科技大学, 2024.
- [19] 承向军, 常歆识, 杨肇夏. 基于 Q-学习的交通信号控制方法 [J]. 系统工程理论与实践, 2006(8): 136–140.
- [20] 卢守峰, 张术, 刘喜敏. 平均排队长度差最小的单交叉口在线 Q 学习模型 [J]. 公路交通科技, 2014, 31(11): 116–122.
- [21] 江波, 李彦冬, 刘威陇, 等. 应用深度 Q 学习的机场道口协同智能调速方法 [J]. 航空计算技术, 2022, 52(1): 26–30.
- [22] 张春阳, 席雅琪. 人工智能在城市交通控制中的应用综述 [J]. 信息系统工程, 2024(07): 33–36.
- [23] GHAVAMZADEH M, MAHADEVAN S, MAKAR R. Hierarchical multi-agent reinforcement learning[J]. Autonomous Agents and Multi-Agent Systems, 2006, 13(2): 197–229.
- [24] TUMER K, AGOGINO A. Improving air traffic management with a learning multiagent system[J]. IEEE Intelligent Systems, 2009, 24(1): 18–21.
- [25] BACCHINI A, CESTINO E. Electric VTOL configurations comparison[J]. Aerospace, 2019, 6(3): 26.
- [26] U.S. Department of Defense. Flying qualities of piloted airplanes: MIL-F-8785C[S]. Washington, DC: U.S. Department of Defense, 1980.
- [27] LIANG X, MA Y, FENG Y, et al. PTR-PPO: proximal policy optimization with prioritized trajectory replay[EB/OL]. arXiv:2112.03798, 2021.

- [28] CONG W, ZHANG S, CHEN J, et al. Do we really need complicated model architectures for temporal networks?[C]//Proceedings of the 11th International Conference on Learning Representations (ICLR 2023). Kigali: ICLR, 2023.
- [29] XIE Y B, GARDI A, SABATINI R. Reinforcement learning-based flow management techniques for urban air mobility and dense low-altitude air traffic operations[C]//2021 IEEE/AIAA 40th Digital Avionics Systems Conference (DASC). Piscataway: IEEE, 2021: 1–10.