

基于动态图注意力网络与多智能体强化学习的 低空交叉路口飞行器协同管控

作者：彭义森 指导老师：韩云祥

四川大学

2026 年 7 月

摘要

城市低空交叉路口中电动垂直起降飞行器（eVTOL）的高密度安全协同管控是先进空中交通面临的关键技术挑战。本文提出一种融合动态图注意力网络（DyGAT）的耦合多智能体强化学习（MARL）模型。模型包含三项核心设计：（1）DyGAT 融合空间注意力、时序注意力与基于物理量的连续动态边权重——该边权重通过三个手工设计的指数核将距离、速度差和航向差编码为 $(0, 1]$ 区间的乘法门控信号（multiplicative gating），对学习注意力进行软性掩码（soft attention mask），引导模型聚焦高风险交互对；（2）分层奖励函数与速度自适应安全距离；（3）课程学习与 episode 级冲突损失加权机制。

在 21 架 eVTOL 的二维交叉路口仿真场景中，与 8 种基线方法进行了系统对比。本文方法的无冲突完成率（CFCR）从 CTDE-MARL 最优基线 MAPPO 的 57.8% 提升至 68.4% ($p < 0.001$, Cohen's $d = 5.27$, 统计效力 $> 99\%$)，最小间隔违反率（MSVR）从 3.0% 降至 2.4% ($p = 0.029$, $d = 1.69$, 效力 $\approx 70\%$)，构成了本文的核心统计贡献。总冲突次数（TC）从 MAPPO 的 20.3 ± 2.4 降至 18.2 ± 2.1 （降幅 10.3%， $d = 0.93$ ），但该差异在 $n = 5$ 样本量下未达统计显著 ($p = 0.180$, 统计效力约 38%) ——TC 的结果应视为方向性证据，需 $n \geq 20$ 的重复实验确认。消融实验表明 DyGAT 是性能贡献最大的模块（移除后 TC 增加 173.6%）。

关键词：低空交通管控；多智能体强化学习；动态图注意力网络；乘法门控注意力掩码；冲突避免；无冲突完成率

1 引言

1.1 研究背景与动机

城市地面交通拥堵的加剧推动了以 eVTOL 为核心的城市空中交通 (UAM) 发展。FAA 预测到 2040 年将有数百万架无人机与 eVTOL 在美国低空空域运行 [1]。城市低空交通具有高密度、强动态特征——飞行器在空间中快速移动，邻域拓扑以秒级频率变化。交叉路口与汇合点的协同管控与冲突避免是低空 UTM 的核心挑战。

传统空中交通流量管理 (ATFM) 采用集中式优化架构 [2]，在可预测场景中效果良好但面临可扩展性挑战。模型预测控制 (MPC) [3]、最优互惠碰撞避免 (ORCA) [4] 与控制屏障函数 (CBF) [5] 等工程方法在形式化安全保证方面具有优势，但在高密度交互场景中趋于保守。

MARL 因其分布式决策与自适应学习特性被成功引入交通管控领域。Agogino 与 Tumer [6,7] 建立了分布式 ATFM 学习框架；Brittain 与 Wei [8] 验证了深度 MARL 的冲突规避能力；Ghosh 等 [9] 提出深度集成 MARL；Li 等 [10] 提出 MS-GRL 采用多尺度图增强 RL 解决密集无人机网络冲突。然而现有工作在三个维度存在不足：

(1) 时空耦合建模不足。多数方法使用全连接或静态图结构 [8,10,11]。当飞行器快速移动时，静态图无法区分“距离相同但相对运动状态不同”的飞行器对——相向高速靠近与同向等速飞行的两对飞行器，即便当前距离相等，冲突风险相差可达数十倍。

(2) 稀疏冲突样本利用不足。冲突属低概率事件，训练中占比通常低于 0.1% [12,13]，在随机采样中极易被淹没。

(3) 环境不确定性建模不足。多数研究忽略物理运动约束与动态安全距离 [11]，且风扰与噪声模型过于简化。

1.2 主要贡献

- (1) 构建了面向低空交叉路口冲突规避的仿真环境，引入速度自适应安全距离与 eVTOL 物理运动约束；
- (2) 提出 DyGAT 网络，首次在 GAT 框架中引入基于物理量的乘法门控注意力掩码——该机制通过三个手工设计的指数核将几何先验编码为 $(0, 1]$ 区间的软性掩码信号，引导学习注意力聚焦高风险交互对（消融中移除使 TC 增加 173.6%）；
- (3) 设计课程学习与 episode 级冲突损失加权 ($\lambda = 2.0$)，在严格保持 PPO on-policy 框架的前提下提升稀疏冲突样本训练效率；
- (4) 构建双层评价指标体系，揭示 PCR (99.1%) 与 CFCR (68.4%) 之间的系统性差距；

- (5) 与 8 种基线方法系统对比, 包含 Welch t 检验、Cohen's d 效应量和统计功效分析。

2 相关工作

2.1 传统 ATFM 与工程安全方法

传统 ATFM 包括整数规划与欧拉模型线性规划 [2]。工程方法中, MPC [3] 通过滚动时域优化实现预测性控制; ORCA [4] 基于速度空间几何约束实现分布式避障; CBF [5] 提供形式化安全保证。本文实验纳入 ORCA (基于 RVO2 库的 pyrvo 绑定, $\tau = 5.0$ s, 安全半径与 d_{safety} 一致, 首选速度 70 ± 10 km/h 指向中心)。VO 作为 ORCA 前身, 在 $N = 21$ 高密度场景中性能被 ORCA 一致主导 (TC 更高、CFCR 更低), 主实验仅报告 ORCA。MPC 在 21 架飞行器场景下存在实时性约束, 与 MARL 的混合架构是重要研究方向。

2.2 强化学习与 GNN 在交通管控中的应用

单智能体 RL 方面, DQN 应用于冲突规避与信号控制 [12, 15–22]。多智能体 RL 方面, Tumer 与 Agogino [7, 14, 24] 验证了分布式 ATM 架构的有效性; 翟子洋等 [13] 梳理了 CTDE 方法演进路线。Li 等 [10] 的 MS-GRL 采用多尺度 GAT 与 Double DQN 处理 100 架 UAV 冲突, 与本文差异详见第 5.1 节。

GNN 在交通管控中的应用日益广泛 [10]。但现有 GNN 方法中的图结构通常基于固定距离阈值, 忽略了飞行器间相对运动状态差异。DyGAT 的乘法门控注意力掩码直接回应了这一局限——通过物理量驱动连续边权重, 区分“距离相同但风险不同”的飞行器对。

地面交通信号控制的 RL 研究为本文提供方法论参考。Aslani 等 [12] 验证了 actor-critic 架构的优势; 赖建辉 [17] 探索了优先经验回放; 翟子洋等 [13] 指出 CTDE 在多路口协同中的潜力。

3 问题建模与管控模型设计

本文聚焦城市低空十字交叉路口场景: N 架 eVTOL 从均匀分布于圆周的不同方向飞向交叉区域中心, 需在保持安全间隔的前提下以最小延迟通过。

3.1 分布式马尔可夫决策过程形式化

将协同管控定义为 Dec-MDP 六元组 $\langle \mathcal{N}, \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$:

- **智能体集合** $\mathcal{N} = \{1, \dots, N\}$: 训练阶段 N 由课程学习从 5 增至 21。

- **全局状态 S :** $S = (s_1, \dots, s_N)$, $s_i = [x_i, y_i, v_i, v_i^{\text{target}}, d_i^{\text{center}}]$ 。需严格区分：该五维向量是 Dec-MDP 的形式化定义；策略网络的实际输入是经扩展后的局部观测 o_i (第 3.2.1 节)。 S 仅在 CTDE 训练阶段供 GAT-Mixer 计算全局价值函数。
- **动作/转移/奖励/折扣 $\mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma$:** 联合连续加速度 $a_i \in \mathbb{R}$ (m/s^2)，受运动学、风扰和噪声共同影响， $R = \frac{1}{N} \sum_i r_i$, $\gamma = 0.99$ 。

3.2 环境模型

3.2.1 观测空间的三层定义

第一层——形式化状态 $s_i \in \mathbb{R}^5$: $[x_i, y_i, v_i, v_i^{\text{target}}, d_i^{\text{center}}]$ 。

第二层——局部观测 o_i : 在 s_i 基础上扩展：(a) 空间维度——邻域飞行器 $j \in \mathcal{N}_i$ (500 m 半径) 的 $[\Delta x_{ij}, \Delta y_{ij}, \Delta v_{ij}, a_j, \theta_j]$ ，共 $K \cdot 6$ 维 ($K = |\mathcal{N}_i|$)；(b) 时间维度——自身最近 $T = 10$ 步 (5 s) 历史状态序列，共 $T \cdot 5$ 维。

第三层——编码特征 $h_i^{\text{coupled}} \in \mathbb{R}^{256}$: $o_i \xrightarrow{\text{LSTM}_{64}} h_i^{\text{traj}} \xrightarrow{\text{DyGAT}_{256}} h_i^{\text{coupled}} \rightarrow \text{策略/Q 值输出}$ 。

3.2.2 动作空间与物理运动约束

连续加速度 $a_i \in [-4.0, 3.0] \text{ m/s}^2$ 。需要诚实指出：当前主流 eVTOL 制造商 (Joby、Volocopter、Lilium、Archer 等) 均未公开发布最大水平加速度的精确技术规格。学术文献对 eVTOL 性能建模通常假设加速度约 2.0 m/s^2 [25]。本文取最大加速度 3.0 和最大减速度 4.0 m/s^2 ——减速度高于加速度符合安全设计惯例。这些取值为缺乏制造商精确数据下的估计值，在更精确数据可用时应进行敏感性验证。速度范围 $[60, 140] \text{ km/h}$ 参考当前主流 eVTOL 技术水平，最大转弯角 $\pi/6$ (30°)。速度更新：

$$v_i^{t+1} = \text{clip}(v_i^t + a_i \cdot 0.5 \cdot 3.6, 60, 140) \quad (1)$$

3.2.3 不确定性建模与动态安全距离

传感器噪声 $\mathcal{N}(0, 0.5^2) \text{ m}$ (仅观测通道)。风扰 $\theta_w \sim \mathcal{U}(0, 2\pi)$ 、强度 0.1 m/s 。真实风场常使用 Dryden (MIL-F-8785C) [26] 或 Kaimal (IEC 61400-1) 谱模型——当前简化是本文的一项已知局限。动态安全距离 $d_{\text{safety}} = d_{\text{base}} + \bar{v} \times 0.5$, $d_{\text{base}} = 50 \text{ m}$ 。

3.3 分层奖励函数

$$r_i = r_{\text{safe}} + r_{\text{speed}} + r_{\text{coop}} + r_{\text{eff}} \quad (2)$$

安全奖励 (三段式): $d_{\min} < d_{\text{safety}}$ 指数惩罚, $d_{\text{safety}} \leq d_{\min} < 1.2d_{\text{safety}}$ 线性过渡, $d_{\min} \geq 1.2d_{\text{safety}}$ 正奖励。

速度奖励：理想区间 $[65, 90]$ km/h（与目标 70 ± 10 及范围 $[60, 140]$ 一致）：

$$r_{\text{speed}} = \begin{cases} -50(v_i - 90)/50, & v_i > 90 \\ -30(65 - v_i)/5, & v_i < 65 \\ 20, & 65 \leq v_i \leq 90 \end{cases} \quad (3)$$

协同奖励： $r_{\text{coop}} = -0.2|v_i - \bar{v}_{\text{neighbor}}|$ 。 **效率奖励：** $r_{\text{eff}} = -0.5|v_i - v_i^{\text{target}}|$ 。

全局奖励 $R = \frac{1}{N} \sum_i r_i$ ，全通过 +200 完成奖励。

3.4 动态图注意力网络 (DyGAT)

3.4.1 空间注意力

以 LSTM 编码特征 $h_i^{\text{traj}} \in \mathbb{R}^{64}$ 为节点特征 ($F_{\text{out}} = 256$)：

$$e_{ij} = \text{LeakyReLU}_{0.2}\left(a^\top [Wh_i^{\text{traj}} \parallel Wh_j^{\text{traj}}]\right), \quad \alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}_i} \exp(e_{ik})} \quad (4)$$

3.4.2 时序注意力

对 $T = 10$ 步历史特征序列计算时序注意力 h_i^{temporal} ，融合系数 $\alpha_{\text{temp}} = 0.3$ ：

$$h'_i = h_i^{\text{spatial}} + 0.3 \cdot h_i^{\text{temporal}} \quad (5)$$

3.4.3 乘法门控注意力掩码

上述空间与时序注意力均为纯学习机制——在没有足够训练数据覆盖所有飞行器交互模式的情况下，学习注意力 e_{ij} 可能产生反物理的模式（如对远距离、航向正交的飞行器给予高注意力）。DyGAT 通过手工设计的物理先验 w_{ij} 作为**乘法门控信号** (multiplicative gating signal)，对学习注意力施加**软性掩码** (soft attention mask)：

$$w_{ij} = \exp\left(-\frac{d_{ij}}{1000}\right) \cdot \exp\left(-\frac{|v_i - v_j|}{20}\right) \cdot \exp\left(-\frac{|\theta_i - \theta_j|}{\pi/4}\right) \quad (6)$$

$$e_{ij}^{\text{final}} = e_{ij} \odot w_{ij} \quad (7)$$

门控机制的理论解释。该设计与标准门控机制（如 LSTM 中的遗忘门 $\sigma(Wx + b)$ ）有本质不同：标准门控通过学习得到门控信号，而本文的 w_{ij} 完全由物理量驱动，不引入可学习参数。这种设计可理解为一种**结构化先验注入** (structured prior injection)—— w_{ij} 定义了注意力可以操作的“有效范围”（软性掩码），学习注意力 e_{ij} 在此范围内进行精细化分配。

以具体数值说明门控效果。考虑四种飞行器对的典型情景 ($N = 21$, $d_{\text{safety}} \approx 85$ m)：

表 1: w_{ij} 在不同飞行器对情景下的门控效果

情景	$d_{ij}(\text{m})$	$ \Delta v (\text{km/h})$	$ \Delta \theta $	w_{ij}	效果 (e_{ij} 缩放比)
近距离同向等速	100	5	$\pi/12$	≈ 0.85	轻度衰减 (17%), 可自由调节
中距同向等速	300	10	$\pi/8$	≈ 0.58	中度衰减 (42%)
中距相向高速	200	40	$\pi/2$	≈ 0.015	强衰减 (98.5%), 降至 1/67
远距航向正交	500	30	$\pi/2$	≈ 0.003	近零衰减 (99.7%), 几乎阻断

门控机制的核心性质: (1) $w_{ij} \in (0, 1]$ 确保物理先验不会完全阻断信息流——最不利情况下 (远距离 + 高速差 + 航向正交) w_{ij} 仍为一个极小正数而非零, 保留了 e_{ij} 在极端条件下发现非常规依赖的可能性; (2) 乘法形式 ($\odot$ 而非 $+$) 使门控是非对称的—— w_{ij} 可以近乎完全压制 e_{ij} , 但 e_{ij} 永远无法“提升”被压制到接近零的注意力权重, 这确保了物理安全约束的不可被学习覆盖; (3) 物理先验计算无需梯度回传, 在 $N = 21$ 时单步仅增加约 0.02 ms 开销。

3.5 单智能体网络与 GAT-Mixer

单智能体网络: 2 层 LSTM 编码器 (64 维) $\rightarrow$ DyGAT 层 (输出 256 维 h_i^{coupled}) $\rightarrow$ 策略头 (2 层 MLP, Tanh, μ_i , $\mathcal{N}(\mu_i, 0.1^2)$ 采样) $\rightarrow$ Q 值头 (3 层 MLP, ReLU)。

GAT-Mixer 混合网络: 各智能体 4 维状态在全连接图上经 GAT 聚合后均值池化, MLP 输出 Q_{tot} 。GAT-Mixer 的设计目标是用 GAT 注意力替代 QMIX 的超网络, 以突破单调性约束并适配 N 动态变化。本文 GAT-Mixer 在架构上独立于 ICLR 2023 的 GraphMixer [28] (后者基于 MLP-Mixer 用于时序链路预测)。

3.6 模型整体架构

图1展示了模型架构: 每个智能体以自身 5 维状态 (位置、速度、目标速度、距中心距离) 和 500m 范围内邻居的 6 维信息为输入, 首先通过 LSTM 将 $T = 10$ 的时序观测编码为 64 维轨迹特征, 随后送入核心模块 DyGAT (动态图注意力网络), 该网络在标准空间 GAT 的基础上引入两项关键设计——以温度 $\tau = 0.3$ 融合时序调制信息, 并通过乘法门控 $w_{ij} = \exp(-d_{ij}/1000) \times \exp(-|v_i - v_j|/20) \times \exp(-|\psi_i - \psi_j|/(\pi/4))$ 作为软注意力掩码, 将距离差、速度差和航向角差等物理先验直接注入注意力分数 ($e_{ij}^{\text{final}} = e_{ij} \cdot w_{ij}$), 实现对邻居的自适应软性筛选, 输出 256 维耦合特征 h_i^{coupled} ; 该特征随后分两路分别经 MLP 生成动作分布 (加速度 $\in [-4.0, 3.0]\text{m/s}^2$) 和局部 Q 值, 奖励由安全性、速度合规、协作和效率四项加权构成。集中训练端采用 GAT-Mixer (4 块 GAT+MLP) 将各智能体的局部 Q 值单调混合为全局 Q_{tot} , 并使用 PPO 进行 on-policy 优化, 配合环境端 (智能体数 N 从 5 递增至 21、安全间距 d_{base} 从 80m 递减至 50m) 和算法端 (clip $\epsilon = 2.0$) 的双重课程学习策略。消融实验表明, DyGAT 的乘法门控机制使 TC 指标相比普通 GAT 提升 173.6%, 最终在 21 架 eVTOL 场景

下达到 99.1% 的冲突预防率 (PCR) 和 68.4% 的无冲突解决率 (CFCR), 单步推理仅需 4.5ms。




图 1: 模型整体架构

3.7 训练机制

3.7.1 课程学习

从 $N = 5$ 、 $d_{\text{base}} = 80 \text{ m}$ 开始。进阶条件 (连续 3 周期满足冲突率 $<$ 阈值且完成率 $> 80\%$): $N \leftarrow \min(N + 2, 21)$, $d_{\text{base}} \leftarrow \max(d_{\text{base}} - 5, 50)$ 。设有回退机制。共 9 个级别。

3.7.2 Episode 级冲突损失加权

严格 on-policy 框架。PPO 裁剪目标：

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (8)$$

$$r_t(\theta) = \pi_\theta(a_t|o_t) / \pi_{\theta_{\text{old}}}(a_t|o_t), \quad \epsilon = 0.2.$$

$$L_{\text{total}} = \lambda(L_{\text{policy}} + L_q + 0.5L_{\text{value}}), \quad \lambda = \begin{cases} 2.0, & \text{含冲突 episode} \\ 1.0, & \text{无冲突} \end{cases} \quad (9)$$

该机制与优先经验回放（PER）的本质区别：PER 改变采样分布 $\rightarrow$ 期望梯度偏移 $\rightarrow$ 需重要性采样； λ 仅缩放损失幅度 $\nabla_\theta(\lambda L) = \lambda \nabla_\theta L$ ，不涉及 off-policy 数据。关于 λ 与 clip 的交互：clip 作用于 $r_t(\theta)$ 层面；当某 transition 的 $r_t(\theta)$ 被 clip 截断时， λ 对该 transition 无效——因此 λ 加权在训练早期（策略不稳定、clip 截断率高）的实际效果可能弱于预期。PTR-PPO [27] 采用截断重要性采样处理 off-policy 轨迹，代表了更系统的方案。

$\lambda = 2.0$ 在 $\{1.0, 1.5, 2.0, 2.5, 3.0\}$ 上实验确定（表2）。五个离散值的最优未必是连续空间的全局最优。

表 2: λ 取值实验 ($n = 5$)

λ	TC↓	CFCR(%)↑	收敛轮次
1.0	24.6 ± 2.8	53.2 ± 2.3	~ 800
1.5	21.8 ± 2.5	58.7 ± 2.0	~ 600
2.0	18.2 ± 2.1	68.4 ± 1.8	~ 400
2.5	19.5 ± 2.3	64.1 ± 1.9	~ 350
3.0	22.3 ± 3.1	57.3 ± 2.5	~ 300

4 实验与结果分析

4.1 实验设置

PyTorch 实现, NVIDIA RTX 4060 (32 GB) + Intel i9-14900K, Python 3.11。参数见表3。

表 3: 仿真环境参数

参数	取值	参数	取值
空域	1000m $\times$ 1000m	转弯角	$\pi/6$ rad
d_{base}	50 m	T	10 步 (5 s)
Δt	0.5 s	邻域半径	500 m
最大步长	200 步 (100 s)	训练轮次	1000
目标速度	70 ± 10 km/h	γ, ϵ	0.99, 0.2
速度范围	[60, 140] km/h	初始 η	5×10^{-4}
加速度	3.0 m/s^2	减速度	4.0 m/s^2
风扰	0.1 m/s	噪声 σ	0.5 m

4.1.1 基线方法

8 种基线：**规则调度**——RR、FCFS。**单/独立 RL**——集中式 DQN、独立 A2C。**CTDE-MARL**——MADDPG、COMA、QMIX、MAPPO。**工程安全**——ORCA [4] (pyrvo 实现, $\tau = 5.0$ s, 安全半径 = d_{safety} , 首选速度 70 ± 10 km/h 指向中心)。VO 在 $N = 21$ 下被 ORCA 一致主导, 不单独报告。

4.1.2 评价指标

表层: CR、TC、AD。深层: PCR、CFCR (全程零冲突的完成 episode 占比)、MCAE、MSVR。

4.2 训练收敛性分析

三阶段收敛 (图2): I (0–200 轮) 从 -2000 升至 $+800$, TC 从 80 降至 25; II (200–600 轮) 课程学习触发 $N : 11 \rightarrow 19$ 进阶, 每次进阶后 1–3 轮暂时回落; III (600–1000 轮) 奖励稳定在 1286.7 ± 18.2 , TC 收敛至 18.2 ± 2.1 。




图 2: 训练收敛曲线——包含累计奖励（左上）、冲突次数（右上）、平均延迟（左下）与 PCR/CFCR（右下）随训练轮次（0-1000）的变化。

4.3 综合性能对比

表 4: 综合性能对比（21 架 eVTOL, $n = 5$ ）

方法	CR $\uparrow$	TC $\downarrow$	AD(s) $\downarrow$	PCR(%) $\uparrow$
RR	-1256.3 ± 89.2	42.6 ± 5.3	1.58 ± 0.12	89.2 ± 3.5
FCFS	-1187.5 ± 76.4	38.9 ± 4.7	1.42 ± 0.10	91.5 ± 2.8
DQN	-892.5 ± 65.3	28.3 ± 3.9	1.21 ± 0.09	94.7 ± 2.1
独立 A2C	-657.8 ± 52.6	19.7 ± 2.8	0.93 ± 0.07	96.3 ± 1.7
ORCA	-198.7 ± 35.8	22.8 ± 2.9	0.76 ± 0.06	96.0 ± 1.6
MADDPG	-215.6 ± 41.2	25.4 ± 3.2	0.87 ± 0.06	95.8 ± 1.9
COMA	187.3 ± 35.7	22.1 ± 2.9	0.79 ± 0.06	97.1 ± 1.5
QMIX	426.5 ± 28.9	23.1 ± 2.7	0.76 ± 0.05	97.5 ± 1.3
MAPPO	892.4 ± 23.5	20.3 ± 2.4	0.65 ± 0.04	98.2 ± 1.1
本文	1286.7 ± 18.2	18.2 ± 2.1	0.57 ± 0.03	99.1 ± 0.8

学习方法相比 RR 的系统性优势: TC 降 57.2%, AD 缩 63.9%。ORCA (TC=22.8) 显著优于规则方法, 但其 CFCR 仅约 50% (表5), 低于本文 68.4%——ORCA 缺乏多步轨迹预测能力, 高密度下速度空间可行解可能退化。关于本文 vs ORCA 的 TC

差异 (18.2 vs. 22.8, 降幅 20.2%): 以 $n = 5$ 和标准差估算, 该差异的统计显著性可能处于边界状态——系统性的统计比较需 $n \geq 20$ 样本。

4.3.1 安全指标专项对比

表 5: 安全指标对比 ($n = 5$)

方法	CFCR(%)↑	MCAE↓	MSVR(%)↓	PCR(%)↑
RR	12.3 ± 4.1	2.03 ± 0.25	8.7 ± 1.2	89.2 ± 3.5
FCFS	18.7 ± 3.6	1.85 ± 0.22	7.4 ± 1.0	91.5 ± 2.8
ORCA	50.2 ± 3.0	1.09 ± 0.14	3.8 ± 0.6	96.0 ± 1.6
DQN	37.5 ± 3.2	1.35 ± 0.19	5.1 ± 0.8	94.7 ± 2.1
独立 A2C	48.2 ± 2.8	0.94 ± 0.13	3.6 ± 0.6	96.3 ± 1.7
MADDPG	42.6 ± 3.0	1.21 ± 0.15	4.2 ± 0.7	95.8 ± 1.9
COMA	51.3 ± 2.7	1.05 ± 0.14	3.8 ± 0.6	97.1 ± 1.5
QMIX	53.7 ± 2.5	1.10 ± 0.13	3.5 ± 0.5	97.5 ± 1.3
MAPPO	57.8 ± 2.2	0.97 ± 0.11	3.0 ± 0.4	98.2 ± 1.1
本文	68.4 ± 1.8	0.87 ± 0.10	2.4 ± 0.3	99.1 ± 0.8

PCR 与 CFCR 之间约 30 个百分点的系统性差距是本文最重要的实证发现。MAPPO 的差距更大 (约 40 个百分点), 表明该问题是 CTDE-MARL 共性挑战。

4.4 统计显著性检验

Welch t 检验 (双侧, $\alpha = 0.05$, $n_1 = n_2 = 5$) 结果及统计功效分析见表6。

表 6: 本文 vs. MAPPO 统计检验与功效分析

指标	均值差	$t(df=8)$	p	d	Power	结论
TC	-2.1	1.47	0.180	0.93	38%	不显著 ($n \geq 20$ 需)
CFCR	+10.6%	8.34	< 0.001	5.27	> 99%	高度显著
MCAE	-0.10	1.50	0.172	0.95	39%	不显著 ($n \geq 20$ 需)
MSVR	-0.6%	2.68	0.029	1.69	70%	显著

核心统计结论: 本文在 CFCR ($p < 0.001$, 效力 > 99%) 和 MSVR ($p = 0.029$, 效力 70%) 上取得了统计可信的改善——这是本文的核心统计贡献。TC 的差异具有大效应量 ($d = 0.93$) 但在 $n = 5$ 下效力仅 38%——TC 的 $p = 0.180$ 恰当解读为”现有样本量下未检测到显著差异”而非”确认无差异”。需 $n \geq 20$ 以达 80% 效力。

4.5 消融实验

表 7: 消融实验 ($n = 5$)

配置	CR↑	TC↓	AD(s)↓	PCR(%)↑
完整模型	1286.7 ± 18.2	18.2 ± 2.1	0.57 ± 0.03	99.1 ± 0.8
移除 DyGAT (标准 GAT, 无门控)	215.3 ± 32.6	49.8 ± 4.5	0.79 ± 0.05	94.3 ± 1.9
移除课程学习 (直接 $N = 21$)	587.2 ± 27.4	28.4 ± 3.1	0.68 ± 0.04	97.2 ± 1.4
移除冲突损失加权 ($\lambda \equiv 1.0$)	763.5 ± 24.1	24.6 ± 2.8	0.65 ± 0.04	97.8 ± 1.2
同时移除课程学习与冲突加权	128.6 ± 38.5	35.7 ± 3.9	0.82 ± 0.06	95.6 ± 1.7

DyGAT (含乘法门控) 贡献最大: 移除后 TC+173.6%。课程学习与冲突加权作用基本独立 (单独 +56.0% 和 +35.2%, 联合 +96.2%)。

4.5.1 不同飞行器密度的鲁棒性分析

为验证模型在不同交通密度下的鲁棒性, 分别在 5、10、15、21 架 eVTOL 的场景中进行了测试, 结果如图3所示。




图 3: 不同飞行器密度下的冲突次数对比

从图3可以看出:

- (1) 在 5 架低密度场景中, 所有方法的冲突次数均较低, 本文方法与 MAPPO、QMIX 等方法性能接近。
- (2) 在 10 架中密度场景中, 本文方法的优势开始显现, 冲突次数比 MAPPO 低约 15%。
- (3) 在 15 架较高密度场景中, 本文方法的冲突次数比 MAPPO 低约 22%。

- (4) 在 21 架高密度场景中，本文方法的冲突次数仍保持在 19 次以内，而 RR 方法超过 40 次，MAPPO 超过 20 次。本文方法的冲突次数增长斜率显著低于所有基线方法。

这验证了随着交通密度的增加，DyGAT 的时空耦合建模优势愈发显著，模型尤其适合高密度低空交通场景。

4.5.2 敏感性分析

为验证模型对关键参数的敏感性，分别改变基础安全距离、风扰强度、传感器噪声标准差三个参数，测试模型性能的变化，结果如图4所示。




图 4: 敏感性分析结果

从图4可以看出：

- 基础安全距离的影响：**随着基础安全距离增加，冲突次数从 22.5 次减少到 14.7 次，但平均延迟从 0.52s 增加到 0.63s，符合安全与效率的预期权衡关系。
- 风扰强度的影响：**随着风扰强度增加，冲突次数从 16.3 次增加到 20.8 次，增长幅度较小（27.6%），表明模型对风扰具有较好的鲁棒性。
- 传感器噪声的影响：**随着传感器噪声标准差增加，冲突次数从 17.1 次增加到 19.6 次，增长幅度为 14.6%，表明模型对传感器测量误差也具有较好的鲁棒性。

总体而言，模型对关键参数的变化具有较强的鲁棒性，能够在一定范围的扰动下保持稳定的性能。

4.5.3 计算成本分析

为评估模型的实时性，测试了不同飞行器数量下的平均单步推理计算时间，结果如图5所示。




图 5: 不同飞行器数量下的平均单步推理计算时间对比

从图5可以看出：

- (1) 在 21 架 eVTOL 场景中，本文方法的平均单步推理计算时间为 4.5ms，远低于 0.5s 的时间步长，满足实时性要求。
- (2) 传统规则方法（RR、FCFS）计算时间最短（<1ms），但性能最差；COMA 算法计算时间最长，在 21 架飞行器场景中超过 15ms。
- (3) 本文方法的计算时间增长随着飞行器数量的增加较为平缓，表明 DyGAT 和 GraphMixer 的计算开销在可接受范围内。

5 讨论与结论

5.1 与 MS-GRL 的比较

Li 等 [10] 的 MS-GRL 与本文的差异：**算法**——Double DQN（离散）vs PPO（连续）；**图结构**——固定距离阈值 GAT vs 乘法门控动态边权重 DyGAT；**场景**——100 架 UAV vs 21 架 eVTOL 交叉路口。以具体数值说明门控的优势：两对 200 m 的飞行器，同向等速 ($w_{ij} \approx 0.82$) 与相向高速 ($w_{ij} \approx 0.015$)，注意力权重差约 55 倍——固定阈值 GAT 完全无法捕捉该差异。两者在图增强 MARL 路线上互补。

5.2 核心发现与机制解读

CFCR 揭示的安全评估盲区。PCR (99.1%) 与 CFCR (68.4%) 之间约 30 个百分点的差距——在 MAPPO 中更大 (~40 个百分点)——表明仅报告 PCR 可能系统性高估 CTDE-MARL 的安全性能。这一发现不仅适用于本文方法，而是揭示了该领域评估方法论的一个普遍盲区。

乘法门控的贡献结构。DyGAT 整体替换使 TC+173.6%，但其内部三个组件的独立贡献尚未分解。特别是第 3.4.3 节提出 w_{ij} 可能在学习注意力”学坏”时提供必要约束——这引出一个待验证假设：若仅用 w_{ij} 作注意力（不学 e_{ij} ），性能会接近完整 DyGAT 吗？回答此问题需仅 w_{ij} vs 仅 e_{ij} vs $e_{ij} \odot w_{ij}$ 的三路组件级消融。

统计证据的差异化图景与论述重心。本文的核心统计贡献明确定位于 CFCR ($p < 0.001$, $d = 5.27$) 和 MSVR ($p = 0.029$, $d = 1.69$) 的显著改善——这两项指标在安全攸关的评估中具有更直接的工程意义。TC 的差异 ($p = 0.180$, $d = 0.93$) 应视为方向性证据——它表明存在真实效应的可能性（大效应量），但 $n = 5$ 的统计效力不足以确认。将论述重心从 TC 转移到 CFCR/MSVR，是对统计证据强度的诚实反映。

5.3 局限性

(1) **二维场景限制。**当前为二维单交叉路口。三维高度层、多路口网络和起降场约束的扩展是后续工作。

(2) **统计样本量。** $n = 5$ 对 TC 等中等效应量指标检验力不足 (38%)。 $n \geq 20$ 的重复实验是必要的验证步骤。

(3) **风扰与噪声模型。**均匀风扰和高斯白噪声均为时间独立简化模型。真实风场使用 Dryden/Kaimal 谱模型，具有空间相关性和时间连续性。

(4) **通信假设。**CTDE 训练假设全局状态无延迟获取。实际 UTM 部署中通信存在延迟 (50–200 ms) 和丢包。

(5) **基线覆盖。**MPC 和 CBF 尚未纳入比较。ORCA 已进行场景适配调优，但未对所有基线进行系统性超参数搜索。

(6) **eVTOL 动力学参数。**加速度取值 ($3.0\text{--}4.0\text{ m/s}^2$) 为参考学术文献 [25] 并在缺乏制造商精确数据下的估计值。当前主流 eVTOL 制造商 (Joby、Volocopter、Lilium、Archer 等) 均未公开发布最大水平加速度的精确规格。在制造商数据可用时需进行参数敏感性验证。

(7) **DyGAT 门控超参数。**三个指数核的衰减常数 (1000 m、20 km/h、 $\pi/4$ rad) 为手工预设，未进行系统化调优，可能限制在不同空域尺度下的泛化性能。

5.4 结论

本文针对城市低空十字交叉路口的 eVTOL 协同管控问题，提出了一种融合乘法门控注意力掩码的耦合 MARL 模型。核心创新为 DyGAT 中基于物理量的乘法门控

机制——将距离、速度差和航向差编码为软性注意力掩码，实现对飞行器间时空耦合关系的细粒度建模。

在 21 架 eVTOL 的二维交叉路口仿真场景中，本文方法在 CFCR (68.4% vs. MAPPO 57.8%, $p < 0.001$, $d = 5.27$) 和 MSVR (2.4% vs. 3.0%, $p = 0.029$, $d = 1.69$) 上取得了统计显著的改善。TC 的差异 (18.2 vs. 20.3, 降幅 10.3%, $d = 0.93$) 具有大效应量但因 $n = 5$ 限制未达统计显著 ($p = 0.180$, 效力 38%) ——该效应的确认需 $n \geq 20$ 的重复实验。

后续工作：(1) 三维多路口网络扩展；(2) $n \geq 20$ 重复实验并补充 vs ORCA 的完整统计比较；(3) 集成 Dryden/Kaimal 标准风谱模型；(4) 引入通信延迟与丢包约束；(5) DyGAT 三路组件级消融（仅 w_{ij} /仅 $e_{ij}/e_{ij} \odot w_{ij}$ ）；(6) 与 MPC/CBF 进行系统基准对比。

可复现性声明：当前版本使用 Python 3.11+PyTorch 实现，实验参数已在表3中完整列出，ORCA 实现基于 pyrvo (RVO2 库 Python 绑定)。独立复现本文结果需约 1000 轮 $\times 400$ episodes $\times 4.5$ ms $\times 1000$ 步 ≈ 5 小时 (RTX 4060 GPU) 每 seed——5 seeds 总计约 25 GPU 小时， $n = 20$ 约需 100 GPU 小时。

参考文献

- [1] Federal Aviation Administration. Urban air mobility (UAM): concept of operations v2.0[R]. Washington, DC: FAA, 2023.
- [2] MENON P K, SWERIDUK G D, BILIMORIA K D. New approach to modeling, analysis, and control of air traffic flow[J]. Journal of Guidance, Control, and Dynamics, 2004, 27(5): 737–744.
- [3] RICHARDS A, HOW J P. Aircraft trajectory planning with collision avoidance using mixed integer linear programming[C]//Proceedings of the 2002 American Control Conference. Piscataway: IEEE, 2002: 1936–1941.
- [4] VAN DEN BERG J, GUY S J, LIN M, et al. Reciprocal n-body collision avoidance[C]//Robotics Research: The 14th International Symposium ISRR (Springer Tracts in Advanced Robotics, Vol. 70). Berlin: Springer, 2011: 3–19.
- [5] AMES A D, COOGAN S, EGERSTEDT M, et al. Control barrier functions: theory and applications[C]//2019 18th European Control Conference (ECC). Piscataway: IEEE, 2019: 3420–3431.
- [6] AGOGINO A, TUMER K. Regulating air traffic flow with coupled agents[C]//Proceedings of the 7th International Conference on Autonomous

- Agents and Multiagent Systems (AAMAS 2008). Richland: IFAAMAS, 2008: 535–542.
- [7] AGOGINO A K, TUMER K. A multiagent approach to managing air traffic flow[J]. Autonomous Agents and Multi-Agent Systems, 2012, 24(1): 1–25.
- [8] BRITTAİN M, WEI P. Autonomous separation assurance in a high-density en route sector: a deep multi-agent reinforcement learning approach[C]//2019 IEEE Intelligent Transportation Systems Conference (ITSC). Piscataway: IEEE, 2019: 3256–3262.
- [9] GHOSH S, LAGUNA S, LIM S H, et al. A deep ensemble method for multi-agent reinforcement learning: a case study on air traffic control[C]//Proceedings of the 31st International Conference on Automated Planning and Scheduling (ICAPS 2021). Palo Alto: AAAI Press, 2021: 468–476.
- [10] LI Y, LI J, WANG J, ZHANG X, DING H, DU W. Multiscale-graph-enhanced reinforcement learning for conflict resolution in dense UAV networks[J]. IEEE Internet of Things Journal, 2025, 12(21): 44290–44303.
- [11] SPATHARIS C, BASTAS A, KRAVARIS T, et al. Hierarchical multiagent reinforcement learning schemes for air traffic management[J]. Neural Computing and Applications, 2021, 33(14): 8649–8671.
- [12] ASLANI M, MESGARI M S, WIERING M. Adaptive traffic signal control with actor-critic methods in a real-world traffic network with different traffic disruption events[J]. Transportation Research Part C: Emerging Technologies, 2017, 85: 732–752.
- [13] 翟子洋, 郝茹茹, 董世浩. 大规模智慧交通信号控制中的强化学习和深度强化学习方法综述 [J]. 计算机应用研究, 2024, 41(6): 1618–1627.
- [14] TUMER K, AGOGINO A. Distributed agent-based air traffic flow management[C]//Proceedings of the 6th International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS 2007). Honolulu: ACM, 2007: 330–337.
- [15] 王迎. 城市交通信号控制深度强化学习算法研究 [D]. 济南: 山东交通学院, 2024.
- [16] 赵晓华, 石建军, 李振龙, 赵国勇. 基于 Q-learning 和 BP 神经网络的交叉口信号灯控制 [J]. 公路交通科技, 2007, 24(7): 99–102.
- [17] 赖建辉. 基于深度强化学习的交通控制优化方法研究及实现 [D]. 杭州: 浙江工业大学, 2020.

- [18] 张新武. 基于深度强化学习算法的交通信号控制优化研究 [D]. 太原: 太原科技大学, 2024.
- [19] 承向军, 常歆识, 杨肇夏. 基于 Q-学习的交通信号控制方法 [J]. 系统工程理论与实践, 2006(8): 136–140.
- [20] 卢守峰, 张术, 刘喜敏. 平均排队长度差最小的单交叉口在线 Q 学习模型 [J]. 公路交通科技, 2014, 31(11): 116–122.
- [21] 江波, 李彦冬, 刘威陇, 等. 应用深度 Q 学习的机场道口协同智能调速方法 [J]. 航空计算技术, 2022, 52(1): 26–30.
- [22] 张春阳, 席雅琪. 人工智能在城市交通控制中的应用综述 [J]. 信息系统工程, 2024(07): 33–36.
- [23] GHAVAMZADEH M, MAHADEVAN S, MAKAR R. Hierarchical multi-agent reinforcement learning[J]. Autonomous Agents and Multi-Agent Systems, 2006, 13(2): 197–229.
- [24] TUMER K, AGOGINO A. Improving air traffic management with a learning multiagent system[J]. IEEE Intelligent Systems, 2009, 24(1): 18–21.
- [25] BACCHINI A, CESTINO E. Electric VTOL configurations comparison[J]. Aerospace, 2019, 6(3): 26.
- [26] U.S. Department of Defense. Flying qualities of piloted airplanes: MIL-F-8785C[S]. Washington, DC: U.S. Department of Defense, 1980.
- [27] LIANG X, MA Y, FENG Y, et al. PTR-PPO: proximal policy optimization with prioritized trajectory replay[EB/OL]. arXiv:2112.03798, 2021.
- [28] CONG W, ZHANG S, CHEN J, et al. Do we really need complicated model architectures for temporal networks?[C]//Proceedings of the 11th International Conference on Learning Representations (ICLR 2023). Kigali: ICLR, 2023.
- [29] XIE Y B, GARDI A, SABATINI R. Reinforcement learning-based flow management techniques for urban air mobility and dense low-altitude air traffic operations[C]//2021 IEEE/AIAA 40th Digital Avionics Systems Conference (DASC). Piscataway: IEEE, 2021: 1–10.